

基于视觉语言模型反馈与强化学习优化的 世界模型后训练研究

Post-Training of World Models Based on Vision-Language Model Feedback and
Reinforcement Learning Optimization

答辩人	答辩人姓名
学号	XXXXXXXXXXXX
指导教师	XXX 老师
学院	XX 学院
专业	20XX 级 XX 专业
日期	20XX 年 X 月 X 日

01 研究背景与动机

视频生成世界模型的物理常识缺陷

02 方法设计

物理事件提示词构建 + VLM 反馈的 Flow-GRPO
后训练策略

03 实验验证

设置、实验结果、消融实验与定性分析

04 总结与展望

贡献与未来展望

01

研究背景与动机

新一代世界模型（视频生成模型）

- Sora、Veo、Kling、Wan 等模型已能根据文本提示生成高分辨率的视频，初步具备对真实世界的建模能力。
- 支持文本到视频、图像到视频等多种生成模式，单帧画质和时间一致性持续提升。
- 该方向正在从单纯的内容生成向世界模拟器演进，有望成为机器人仿真、具身智能和科学可视化的基础工具。

物理常识缺陷

- **现状：**物体穿透、重力失效、碰撞无响应，材料形变与流体边界失真等。
- **表现：**模型倾向于生成视觉上“好看”但不符合物理规律的视频。
- **为何重要：**缺乏物理常识的视频模型无法支撑需要物理一致性的下游任务，如机器人策略学习和自动驾驶仿真。

显式物理引擎

优势：封闭场景中物理约束明确，可解释性强。

困境：开放域场景远超仿真器覆盖范围，需要精确初始条件，文本提示通常无法提供。

统一多模态大模型

优势：从头预训练融合理解与生成，能力完整。

困境：需数千 GPU 和 PB 级数据，物理正确视频占比极小，易拟合虚假统计模式。

离线对齐

优势：不需要在线采样，从配对好坏视频数据中学习偏好。

困境：训练数据固定，模型无法探索新策略并获得即时反馈，静态偏好数据无法持续改进。

研究动机

在不依赖物理模拟器的前提下，通过视觉语言模型反馈和在线强化学习让世界模型生成的视频更符合物理规律。

1. 构建物理提示词集

构建并筛选物理提示词数据集，覆盖重力碰撞、材料流体等方面。

2. 视觉语言模型双维度奖励

通过 PC 和 SA 两个维度，分别约束物理常识和语义贴合，减少奖励作弊行为。

3. 强化学习后训练策略


参照 Flow-GRPO 论文实现代码，完成 SDE 采样、群组相对优势估计与 LoRA 参数更新。

4. 多维度实验验证

通过 VBench2.0、人工偏好、消融实验和跨模型实验验证训练有效性。

02

方法设计



三阶段流程

- ❶ **候选生成**：围绕物理常识，由大语言模型批量构造描述。
- ❷ **物理筛选**：由 GPT-4o 判断候选是否真正涉及物理事件，剔除静态场景。
- ❸ **人工筛查**：处理边界样本与歧义结果，保证最终提示词可观察、可评价。

设计原则

- **明确三要素**：每条提示词必须包含初始状态、动作过程和可观察后果。
- **排除不可评样本**：排除静态氛围、隐藏状态和多义结果。
- **聚焦物理事件**：让奖励聚焦物理事件本身，而非一般视觉质量。

生成候选提示词的模板

Generate prompts testing physical commonsense.

Each prompt should:


- Describe initial state, action, consequence
- Involve gravity, collision, material, fluid, human action, causal chains
- Be observable in short video, no audio/text

GPT-4o 筛选的提示词

Evaluate prompt for physical commonsense test.

1. Truly involve physical event, not static
2. Clear action and observable consequence
3. Evaluable without audio, text, hidden states
4. Unambiguous outcome

Score 1-5, where 5 = clear physical event



物理常识奖励 PC

- 重力方向与运动趋势是否合理。
- 碰撞响应、不可穿透约束。
- 材料形变、液体边界。

r_{PC}

Role: Expert in physical commonsense.
Criteria: motion, force, gravity, collisions,
 material, causality.
Output: Score: X (1-5)

语义贴合奖励 SA

- 主体、动作、场景是否出现。
- 关键视觉细节是否匹配。
- 防止静止化或模糊化逃避物理错误。

r_{SA}

Role: Expert video analysis judge.
Criteria: objects, actions, scene,
 temporal order, visual details.
Output: Score: X (1-5)

Flow-GRPO 的损失函数

$$L = \underbrace{-\mathbb{E} \left[\min \left(\rho_t \hat{A}, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) \hat{A} \right) \right]}_{L_{\text{pg}}: \text{策略梯度损失}} + \underbrace{\beta \cdot L_{\text{KL}}}_{\text{KL 正则项}}$$

策略比值 ρ_t

$$\rho_t = \frac{p_{\theta}(z_{t-1} | z_t, c)}{p_{\theta_{\text{old}}}(z_{t-1} | z_t, c)}$$

衡量新旧策略在同一转移上的概率比。 $\rho_t > 1$ 表示新策略更倾向于该动作。

优势估计 $\hat{A}$

$$\hat{A} = w_{\text{PC}} \hat{A}_{\text{PC}} + w_{\text{SA}} \hat{A}_{\text{SA}}$$

群组内标准化后的奖励， $\hat{A} > 0$ 表示优于平均水平。

$$\hat{A}_h = \frac{r_h - \mu_{c,h}}{\sigma_{c,h} + \epsilon}$$

KL 正则项 L_{KL}

$$L_{\text{KL}} = \frac{\|\mu_{\theta} - \mu_{\text{ref}}\|_2^2}{2\sigma_t^2 \Delta t}$$


约束当前策略不偏离参考模型太远，防止灾难性遗忘。

直觉理解： $\rho_t \hat{A} > 0$ 时增大该转移概率， $\rho_t \hat{A} < 0$ 时减小；clip 限制单步更新幅度， β 控制保守程度。

代码实现流程

输入：基础生成器 π_{θ_0} ，参考策略 π_{ref} ，提示词集 $\mathcal{D}$ ，评估器 J_{PC} 和 J_{SA} ，组大小 G ，KL 权重 β ，截断范围 ε

```
初始化  $\pi_{\theta} \leftarrow \pi_{\theta_0}$ ，加载 LoRA 适配器 // 加载基础模型
For 每个训练轮次 do
  从  $\mathcal{D}$  采样提示词批次  $\mathcal{C}$  // 采样提示词
  For 每个提示词  $c \in \mathcal{C}$  do
    For  $i = 1, \dots, G$  do // 采样  $G$  条候选
       $(x_i, \tau_i, \ell_i^{\text{old}}) \leftarrow \text{SDESAMPLE}(\pi_{\theta}, c)$ 
       $r_{i,\text{PC}} \leftarrow J_{\text{PC}}(x_i, c)$ ;  $r_{i,\text{SA}} \leftarrow J_{\text{SA}}(x_i, c)$  // VLM 评分
    end for
     $\hat{A}_{i,h} \leftarrow (r_{i,h} - \mu_{c,h}) / (\sigma_{c,h} + \epsilon_{\text{std}})$  // 群组内标准化
     $A_i \leftarrow \text{clip}(w_{\text{PC}} \hat{A}_{i,\text{PC}} + w_{\text{SA}} \hat{A}_{i,\text{SA}}, -A_{\text{max}}, A_{\text{max}})$  // 加权组合
    For 每个转移  $(z_t, z_{t-1}, c)$  do
       $\rho_i \leftarrow \exp(\log p_{\theta}(z_{t-1}|z_t, c) - \ell_i^{\text{old}})$  // 策略比值
       $L_{\text{pg}} \leftarrow -\text{mean}\{\min(\rho_i A_i, \text{clip}(\rho_i, 1 - \varepsilon, 1 + \varepsilon) A_i)\}$ 
       $L_{\text{KL}} \leftarrow \text{STEPKL}(\pi_{\theta}, \pi_{\text{ref}}; z_t, c)$ 
      更新 LoRA:  $L_{\text{pg}} + \beta L_{\text{KL}}$  // 梯度更新
    end for
  end for
end for
```



- **Actor** 节点接收物理事件提示词，采样同一提示词下的 G 条候选视频，记录旧策略概率，将视频发送给 Judge。
- **VLM Judge** 节点对每条视频独立输出 PC 与 SA 双维度奖励分数，将评分结果发送给 Trainer。
- **Trainer** 节点在群组内标准化奖励、计算优势估计，通过 Flow-GRPO 更新 LoRA 参数，再将新权重同步回 Actor。

03

实验验证


模型与训练配置

- 主实验: Wan2.2-TI2V-5B
- 跨模型: Wan2.1-T2V-1.3B
- 分辨率 704×1248 , 帧数 81
- 采样步数: 50
- AdamW, 学习率 3×10^{-5}
- LoRA: rank=32, alpha=64; 冻结文本编码器和 VAE

Flow-GRPO 与 VLM 配置


- 群组大小 $G = 4$
- PC 和 SA 权重均为 0.5
- 噪声: $\sigma = 0.3$
- KL 系数 $\beta = 10^{-3}$, 优势截断 5.0
- VLM 评估器: 评分范围 1 到 5

提示词数据分布



- 覆盖重力与碰撞、材料与流体、人体动作、因果事件四类物理现象。
- 每条提示词应包含明确动作、可观察后果和较少歧义的物理判断标准。

VBench2.0 主实验结果



模型	人体身份	人体结构	力学	热学	材料	运动合理性	复杂情节
Wan2.2 基线	0.638	0.771	0.702	0.710	0.704	0.431	0.123
本文	0.760	0.877	0.731	0.737	0.732	0.459	0.156
Δ	+19.2%	+13.8%	+4.2%	+3.8%	+3.9%	+6.4%	+26.5%
Wan2.1 基线	0.631	0.758	0.639	0.691	0.789	0.420	0.111
本文	0.685	0.802	0.674	0.721	0.813	0.447	0.139
Δ	+8.5%	+5.7%	+5.5%	+4.5%	+3.0%	+6.6%	+25.9%

物理相关维度均提升，同时用跨模型验证了框架通用性

50 条提示词，3 名评测者盲测，多数投票决定偏好。

对比	本文	基线	平局
Wan2.2	28	15	7
Wan2.1	25	12	13

σ	力学	运动合理性	复杂情节
基线	0.702	0.431	0.123
0.1	0.717	0.444	0.119
0.3	0.731	0.459	0.156
0.7	0.665	0.398	0.091

$\sigma = 0.3$ 在探索与视频质量之间取得较好平衡， σ 过小则探索不足，过大则视频质量下降。


定性分析：油倒入牛奶



基线：油与牛奶混合，不符合物理规律。

本文：黄色薄层更清晰，流体边界更稳定，符合物理规律。

训练过程：KL 正则化稳定性



KL 曲线未持续发散，说明物理对齐主要是局部行为修正，策略更新受控。

04

总结与展望

- **构建物理提示词集**：构建并筛选提示词，覆盖重力碰撞、材料流体等。
- **视觉语言模型双维度奖励**：设计 PC 和 SA 双维度视觉语言模型奖励，分别约束物理常识和语义贴合，减少奖励作弊。
- **轻量级的框架**：实现了轻量级的物理对齐，即不需要物理模拟器，只用 LoRA 微调 0.4% 的参数，完成物理对齐。
- **多维度实验验证**：通过 VBench2.0、人工偏好、消融实验和跨模型实验验证物理后训练有效性。

- **过程奖励建模**：当前奖励机制是结果级的，VLM 对完整视频给出一个标量分数。未来可探索过程奖励建模（PRM），将物理验证分解为逐帧或逐事件评估，以杯子坠落碎裂为例，可分别评估是否离开桌面、下落轨迹是否符合重力、碎裂形态是否合理，提供更密集的信号帮助模型定位和修正具体物理错误。
- **隐空间物理属性解耦**：在视频模型隐空间内将物体的内在物理属性（例如质量、材质）与外在视觉特征（纹理、光影）解耦，通过引入显式物理语义约束，增强零样本物理推理能力和多对象交互场景的生成一致性。
- **多粒度评估与自适应训练**：根据模型在不同物理类别上的表现差异，自适应调整训练策略，对表现较差的类别增加训练强度，进一步提高物理对齐效果。

谢谢各位老师

请各位老师批评指正

答辩人	答辩人姓名
学号	XXXXXXXXXX
指导教师	XXX 老师
学院	XX 学院
专业	20XX 级 XX 专业
日期	20XX 年 X 月 X 日